

综 述

doi: 10.3969/j.issn.1673-5692.2025.01.001

基于深度学习的波达方向估计方法综述

刘其有^{1,2}, 何 瑞^{1,2}, 施 伟²

(1. 南京信息工程大学 电子与信息工程学院, 江苏 南京 210044;

2. 国防科技大学第六十三研究所, 江苏 南京 210007)

摘 要: 在阵列信号处理中, 波达方向 (Direction of Arrival, DOA) 估计是一项核心任务, 旨在确定信号源相对于阵列传感器的方向。随着深度学习 (Deep Learning, DL) 技术的兴起, 其在 DOA 估计领域的应用已取得显著成果。本研究回顾了 22 篇关于基于 DL 的 DOA 估计方法的文献, 分析了这些研究的发表背景、引用频次, 并系统探讨了 DL 在 DOA 估计中的具体应用, 包括目标、模型和方案。通过评价指标 (如 RMSE、MSE) 对这些方法进行了评估, 并探讨了信噪比、信号数量、阵元数和快照数等因素对 DOA 估计的影响。此外, 本研究还特别关注了多输入多输出 (Multiple Input Multiple Output, MIMO) 雷达阵列在多源 DOA 估计方面的最新进展。

关键词: 深度学习; DOA 估计; 阵列误差; MIMO 雷达

中图分类号: TN957 文献标志码: A 文章编号: 1673-5692(2025) 01-001-09

Survey of DOA Estimation Methods Based on Deep Learning

LIU Qi-you^{1,2}, HE Rui^{1,2}, SHI Wei²

(1. School of Electronic and Information Engineering, Nanjing University of Information Science & Technology, Nanjing 210044, China;

2. The Sixty-third Research Institute, National University of Defense Technology, Nanjing 210007, China)

Abstract: Direction of Arrival (DOA) estimation, pivotal in array signal processing, determines signal source directions relative to array sensors. The integration of deep learning (DL) has significantly advanced DOA estimation. This review examines 22 DL-based DOA estimation approaches, assessing their publication context and scholarly impact. It delves into DL's role, encompassing objectives, models, and schemes, and evaluates them using metrics like RMSE and MSE. The review also investigates factors affecting DOA estimation, such as signal-to-noise ratio (SNR), signal count, array element number, and snapshot quantity. Special emphasis is placed on advancements in multi-source DOA estimation for MIMO radar arrays.

Key words: deep learning; DOA estimation; array error; MIMO radar

0 引 言

波达方向 (Direction of Arrival, DOA) 估计是阵列信号研究领域的一个核心议题, 在现代雷达、无线电通信、导航等应用场景中, 需追求高精度、高效率、

鲁棒性更强的 DOA 估计方法^[1]。传统的 DOA 估计算法集中在理想天线阵列上, 其模型通常与实际应用场景存在很大差异。例如, 在传统的 DOA 估计技术中, 常规波束赋形法 (Conventional Beam Forming, CBF)^[2] 是一种常用的实现手段, 该方法由于严格的物理约束, 其角度分辨率受到“瑞利限”的影响。因

收稿日期: 2024-09-04 修订日期: 2024-11-10

基金项目: 国家自然科学基金资助项目 (62401593)

为模型驱动方法的性能严重依赖于天线阵列的孔径,所以为了实现高分辨率的 DOA 估计,接收阵列应该具有相对较大的孔径。这意味着,为了获得高分辨率,需要具有大量天线的阵列,这种方法并不高效。Capon 空间谱估计法^[3]成功克服了 CBF 所遭遇的“瑞利限”,从而实现了空间分辨率的显著增强,但是需要在高信噪比(Signal to Noise Ratio, SNR)、多快拍的条件下才能达到高精度估计。子空间分类算法的重要代表有多重信号分类法(Multiple Signal Classification, MUSIC)^[4]和旋转不变子空间参数估计法(Estimation of Signal Parameters via Rotational Invariance Techniques, ESPRIT)^[5]。MUSIC 算法通过对阵列接收到的协方差矩阵实施特征值或奇异值的分解,从而识别出信号和噪声所在的子空间。ESPRIT 算法通过利用子空间的不变性特征,提取子阵列信号的相位差异以实现信号入射角的估计。但这两种子空间分类算法在低 SNR、少快拍等非理想情况下,测向性能会显著下降,且无法对相干信号源进行有效处理。

随着稀疏恢复(Sparse Recovery, SR)理论的发展^[6],研究人员对 DOA 估计算法研究有了新的思路。利用信号在空域内是稀疏的先验条件,通过角度或空间频率域内进行网格划分,可以创建一个包含导向矢量的字典,这样做有助于揭示阵列采集数据的稀疏本质。将波达方向的估计任务转换为稀疏信号恢复问题后,便能够利用单次快照数据实现对相干信号源的高精度 DOA 估计^[7]。正交匹配追踪法(Orthogonal Matching Pursuit, OMP)^[8]是经典的基于稀疏恢复理论的 DOA 估计方法,尽管该算法具有较低的计算负担和较小的估计偏差,但其实际应用受到一定限制,因为他通常依赖于如信号稀疏性等预先获得的信息。

依赖于模型推动的 DOA 估计技术,在完美假设下能够逼近克拉美罗界限。然而,当面临诸如阵列元件位置偏差、幅度和相位误差等非理想条件导致的模型不匹配时,其估计的准确性可能会遭受显著的衰减^[9]。随着深度学习技术的发展,基于深度学习的 DOA 估计方法受到研究人员的关注。文献[10]设计了专门的卷积神经网络(Convolutional Neural Networks, CNN)应对未知多径信号。文献[11–13]开发基于深度神经网络(Deep Neural Network, DNN)的高效 DOA 估计算法。文献[14–15]提出了基于深度卷积神经网络(Deep Convolutional Network, DCN)的空间谱恢复算法。GNN 等神经网络

模型逐渐进入人们的视野,并逐渐成为 DOA 估计新的研究方向。然而,这种方法在源离网时受到泄漏效应的影响,并且不能有效地解析位于同一波束中的源^[16]。文献[17]提出了一种将两个 DNN 合并的方法,该方法有效地解决了网格失配。文献[18]提出了一种基于 GraphSAGE 结构中的图神经网络(Graph Neural Network, GNN)的新型 DOA 估计算法, GNN 模型可以适应无任何先验信息的非均匀随机稀疏线阵的测角问题,在复杂环境中实现高精度的 DOA 估计。

1 深度学习的介绍

深度学习起源于机器学习和统计力学,机器学习其根源可追溯至数百年乃至更早的时期。机器学习也可以理解成是计算机使用人工神经网络(Artificial Neural Network, ANN)计算大量数据,自主模拟人类学习过程并最终做出最优决策的过程。该方法通过一些有监督或无监督的算法使计算机不断学习一批包含有效信息的样本,并利用获得的一系列决策函数来高效率完成特定任务。ANN 是一种自调整的非线性动态网络系统,由大量互相连接的神经元组成,是对生物神经网络的模拟和近似^[19]。MP 模型^[20]是神经元的第一个数学模型,神经网络由无数个“MP 神经元”相互连接,以一定的几何结构组成。其输出信号可以表示为

$$y_k = f\left(\sum_{i=1}^m w_{ki}x_i + b_k\right) \quad (1)$$

式中: x_i 为神经元的输入; y_k 为输出; w_{ki} 为对应每个神经元输入的权重; b_k 为偏置单元,以常数值加到激活函数的输入中。 f 是激活函数,赋予了神经网络极高的灵活性,并使得网络能够捕捉和处理复杂的非线性关联。文献[21]提出了反向传播(Back-propagation, BP)神经网络,这是建立在梯度下降法的基础上,广泛应用于多层前馈神经网络的学习算法。该算法通过计算损失函数关于网络参数的梯度,并将梯度沿着网络反向传播,以更新网络参数,从而优化模型性能。损失函数通常是描述预测值和真实值之间的接近程度,这里网络参数通常是指权重和偏置。然而,随着网络层数的增加, BP 神经网络存在局部优化、过拟合、梯度扩散等问题^[22],限制了 BP 神经网络的使用。为了解决这些问题,产生了机器学习的一个新分支:深度学习。深度学习能够自动从原始数据中学习特征表示,根据是否有标

记数据及其用途,深度学习可以应用于监督学习、无监督学习、半监督学习甚至是强化学习等多种场景。

在深度学习领域,CNN 因其独特的架构,相较于其他类型的人工神经网络更受青睐,其训练过程如图 1 所示。这种网络通过局部连接和权重共享等设计特点,构建了多层的前馈连接结构。相较于传统的全连接网络,CNN 拥有较少的参数,其核心架构由交替排列的卷积层、池化层以及全连接层组成^[23]。

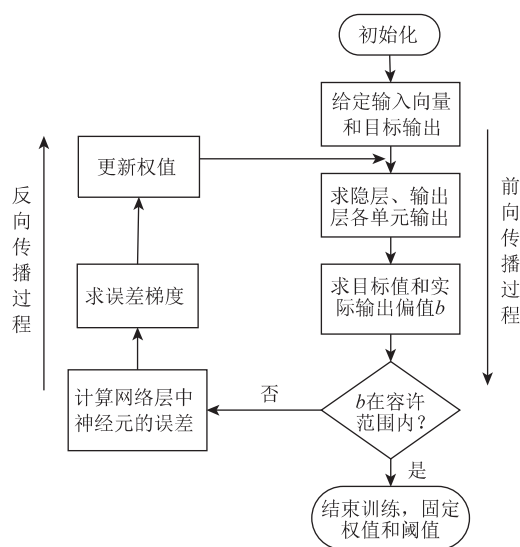


图 1 CNN 训练流程框图

图 2 的卷积层是卷积神经网络中最基础、最核心的组成单元,由许多特征映射组成,每个映射由许多神经元组成。每个神经元通过卷积核连接到前一层的函数图的一部分,卷积核用作权重矩阵,通过卷积核提取输入数据的特征信息。

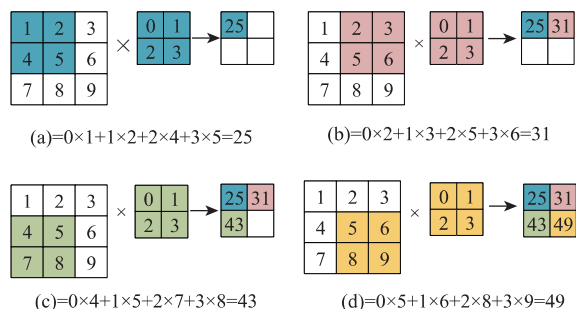


图 2 卷积层

池化层的主要功能在于进一步提炼特征,并减少特征的维度,以此来降低模型过拟合的风险。常用的池化方法包括最大池化和平均池化,如图 3 所示。但是对于一些特定环境下的神经网络,为了防止误删一些特征信息,会避免使用池化层。全连接层在卷积神经网络中起到对样本分类或回归的作

用,该层中的每一个神经元均与前一层的所有神经元实现了彻底的连接。在卷积神经网络正向传播之后进行误差反向传播,用来更新权重和偏置,当模型在训练过程中的误差降至预定的容忍界限之下,或者当预定的迭代次数已经全部执行完毕,此时可以认定神经网络的训练阶段达成终止条件^[24]。




图 3 池化方式比较

递归神经网络 (Recurrent Neural Network, RNN) 能够对序列化的数据进行分析与预测,该网络架构突破了传统机器学习技术在处理输入输出数据时遇到的多种约束,在处理具有时间序列依赖性的数据时表现出卓越的性能。因此,RNN 是深度学习的重要模型^[22]。长短期记忆网络 (Long Short-Term Memory Network, LSTM) 代表了一种对传统 RNN 的改进,LSTM 网络结构包含记忆单元以及输入门、输出门和遗忘门三个门机制。输入门负责调节当前输入数据向记忆单元传递的量,而输出门则决定在当前状态下从记忆单元释放的信息量,这些信息随后用于确定 LSTM 单元输出的激活水平。遗忘门在 LSTM 单元中扮演着至关重要的角色,管理着信息的保留与遗忘,有效防止了在梯度的反向传播过程中出现的梯度衰减和爆炸问题^[25]。

2 综述分析方法

2.1 研究问题的提出

该部分提出了五个问题,描述了使用深度学习进行 DOA 估计的总体趋势,旨在研究 DOA 估计如何受益于深度学习技术。

(1) 数据库中检索选取的文献类型?

(2) 为什么要将深度学习技术应用于 DOA 估计?

(3) 目前有哪些深度学习技术应用于 DOA 估计?

(4) 用于评估 DOA 估计的标准是什么?

(5) 哪些因素会影响 DOA 估计?

2.2 研究文献的选择

对 DOA 估计、深度学习等关键词进行检索,关联到“信号源数量估计”“到达方向”“阵列误差”“稀疏先验”“卷积神经网络”“深度神经网络”“递归神经网络”等术语。选择搜索的数据库包括 PubMed、Web of Science、Sci-Hub、中国知网。

利用 Connected papers、Research rabbit 等文献检索器,使用上述相关术语组合进行检索,共返回 1 959 篇论文,排除了 1 925 篇论文。在选取的过程中,本文对剩余的 34 篇论文进行了分析,并从中选取了 22 篇最接近本文研究主题的论文进行综述,以便让该文章更具有说服力。

3 检索选取文献的理论分析

本节旨在介绍所选取论文的基本信息,同时基于以下发现为 2.1 节的问题(1)提供答案。

图 4 显示了 2018—2024 年的相关文章数量。可以看出,自 2018 年以来,在 DOA 估计研究中使用深度学习技术越来越频繁,并且在 2023 年发表的文章数量最多。




图 4 2018—2024 年相关文章发表数量

各国论文发表数量如图 5 所示。其中,中国的论文占绝大多数,共发表 18 篇,显示了我国高校以及各研究单位的研究人员对此一研究方向的重视程度。其次是英国和德国各一篇论文,日本发表了两篇类似的论文。




图 5 各国发文数量

本文对 22 篇相关论文的被引次数和出版物类型进行了统计,有 2 篇论文发表在会议上,16 篇论文发表在期刊上。为了使本文更具全面性,还选取了 3 篇发表在学报上的相关论文以及 1 篇学位论文。

对已发表论文来说,被引次数越多,作品就越具代表性,越有研究价值。表 1 提供了有关论文被引用次数的统计数据。

表 1 2018—2024 年被审议论文的引用次数

被引次数/次	< 5	5 ≤ 且 < 10	≥ 10
论文数量/篇	14	1	7

从表中可以看出,被引次数小于 5 的论文有 14 篇,被引次数大于等于 5 且小于 10 的论文有 1 篇,被引次数大于等于 10 的论文有 7 篇。此外,应该注意的是,有些论文由于出版时间短,引用次数为零。其中,文献[26]被引用了 501 次;文献[27]被引用了 296 次;文献[28]被引用了 214 次;文献[15]被引用了 103 次;文献[29]被引用了 98 次。

4 DOA 估计中的深度学习

4.1 使用深度学习的目的

本节分析了传统 DOA 估计方法的缺点和 DL 方法的优点,同时也回答问题(2)。第一节提到的算法在各自应用场景下性能优良,但这些算法都是基于所需先验信息已知或理想无干扰的条件完成角度估计。在非理想情况下,实际阵列接收过程会受到很多不可控因素干扰,例如恶劣天气、传输环境介质不均匀、多径干扰、元器件间相互影响等,这些因素会导致一定的误差,直接降低算法的估计性能^[30]。阵列天线接收的相干信号可能引起信号子空间与噪声子空间之间的相互干扰,许多经典的类子空间 DOA 估计算法的精度会因此降低。此外,依赖于模型驱动的 DOA 估计技术的性能受到阵列的物理尺寸限制。同时,在实际应用中,信号源的数目往往是未知的,而大多数 DOA 估计方法都需要事先得知信号源的数目等先验信息^[31]。深度学习是利用足够数量的数据样本来训练模型,然后用训练好的模型对新的输入信息进行结果计算与预测。与传统方法相比,使用深度学习的 DOA 估计方法将 DOA 估计问题转化为模式识别问题。通过提取信号数据的特征进行 DOA 估计,克服了传统 DOA 估

计算法的不足,提高了 DOA 估计的精度。

4.2 参考文献采用的 DL 技术的基本信息

表 2 是阵列模型、DL 模型、激活函数的总结,以

及相关文献使用的网络结构的描述。由表 2 可以清晰地了解到每篇论文所采用的阵列模型,每篇论文所采用的神经网络的架构都各有千秋,从表格的体系结构描述可以快速了解该论文的主要内容。

表 2 所选论文基本信息

参考文献	阵列模型	DL 模型	激活函数	体系结构描述
文献[7]	ULA	DNN	SLO	提出 SLO-Net 用于求解 SR-DOA 模型
文献[10]	ULA	FSL-CNN	ReLU	设计专门的 CNN 应对未知多径信号带来的不利影响
文献[11]	ULA	DRSN+CNN	ReLU +Tanh	DRSN 集成了残差网络、多注意力机制和软阈值
文献[12]	UCA	DNN	ReLU	MIMO 系统的 DOA 估计建模为信号回归问题
文献[13]	ULA	DNN	ReLU	基于 DNN 的网络来学习接收天线的输出与相关 DOA 的非线性映射
文献[14]	ULA+UCA	DCN+FCN	ReLU	利用卷积网络和全连接网络构造了深度学习网络
文献[15]	ULA	DCN	ReLU	提出 DCN 空间谱恢复算法应用于电磁 DOA 估计
文献[16]	ULA	DNN	ReLU	框架可区分比接收天线数量多的信号源
文献[17]	ULA	DNN	ReLU +Sigmoid	DNN 由几个单层神经网络堆叠而成
文献[18]	ULA+RSLAs	GNN	SiLU	引入一种基于残差 GNN 来处理稀疏阵列信号
文献[19]	ULA	CNN	Tanh	运用 CNN 直接学习接收信号与空域参数之间的非线性关系
文献[23]	ULA	CNN	ReLU	以相位差矩阵为输入。
文献[26]	ULA	CNN	ReLU	将空域范围划分为 N 个一定间距的离散角度的集合
文献[26]	ULA	DNN	ReLU +Sigmoid	利用空间结构进行 DOA 估计
文献[27]	ULA	DNN	Tanh	在多层分类器之前引入多任务自编码器
文献[28]	ULA	DCN	Sigmoid	设计基于噪声训练的深度卷积网络
文献[29]	ULA	CNN	ReLU +Sigmoid	引入一个 8 层 CNN
文献[30]	ULA	LSS-2PCNN	SeLU	使用基于 DNN 的网络来学习接收天线的输出与其相关 DOA 的非线性映射。
文献[31]	ULA	CNN	ReLU +Sigmoid	使用具有 1D 卷积层的深度 CNN 来提取鲁棒 DOA 估计的特征
文献[32]	ULA	SC-SSF	ReLU	将矢量奇异值法、循环平稳 DOA 估计算法和 CNN 相结合
文献[33]	ULA	DNN	ReLU +Sigmoid	只能检测两个目标
文献[34]	ULA	DNN	ReLU	多层感知和并行 DNN

图 6~图 8 给出的信息提供了问题(3) 的答案。图 6 总结了 DOA 估计中所采用的接收天线阵列模型,在语音 DOA 估计中使用最多的是 ULA(86%),其次是 UCA(9%),RSLA(5%)。




图 6 阵列模型占比

图 7 是在选定的综述论文的研究工作中应用的

深度学习技术的分布,最常用的 DL 模型是 DNN (36%),其次是 CNN(23%)。其次,是使用一些组合网络(23%),如 SC-SSF、LSS-2PCNN、DCN-FCN、DRSN-CNN 和 FSL-CNN。还有一些很少使用的网络模型(18%),如 GNN、DCN、PhaseDOA-Net 和 SLO-Net。

图 8 总结了用于 DOA 估计的 DL 模型中使用的激活函数。可知,最常用的激活函数是 ReLU (40%),其次是 Sigmoid(23%),Tanh(14%) 和其他(23%)。

综上所述,ULA 是研究人员最常用的接收阵列模型,CNN 和 DNN 是最常用的深度学习模型,ReLU




图 7 神经网络模型占比




图 8 DL 模型采用激活函数占比

是最常用的激活函数。

5 深度学习模型性能验证及 DOA 估计影响因素

本节统计了相关文献的性能指标,分析了影响 DOA 估计的因素,回答研究 2.1 节的问题(4)和(5)。

5.1 性能指标

评估 DL 模型的性能对于验证 DOA 估计算法的质量具有重要意义。为了回答问题(4),本文总结了文献[7]等一系列参考文献中 DL 模型的性能标准,具体如表 3 所示。

由表 3 可知,在一定条件下,文献[26]采用均方误差(Mean-square Error,MSE)作为评价方法时性能最好,MSE 为 0.007 5。文献[32]用均方根误差(Root Mean Square Error, RMSE)作为评价方法时性能最好, RMSE 为 0.02,但是不同方法的性能会受到各种因素的影响,其影响因素在下一节阐述。

图 9 通过计算研究人员使用的不同评估标准的分布来帮助回答(5)。最常用的评价标准是均方根误差、均方误差、归一化均方误差和平均绝对误差,分别占 55%、27%、9%和 9%。

此外,还有一些较少使用的其他评估标准,如绝对误差(AE)、平均误差(ME)和平均准确度(AA)。这里仅对较常用的评价标准进行简要介绍,平均绝对误差(Mean Absolute Error,MAE)、MSE、RMSE 的计算公式为

表 3 DOA 中的参数比较与性能评价

参考文献	信噪比	快拍数	信源数	阵元数	评价指标	评价价值
文献[7]	40	—	未知	40	NMSE	-17.000 00
文献[10]	10	512	2	16	RMSE	0.050 00
文献[11]	0	—	5	8	RMSE	0.124 80
文献[12]	10	—	32	128	NMSE	0.000 45
文献[13]	10	400	2	10	RMSE	0.200 00
文献[14]	10	350	2	10	RMSE	0.280 00
文献[15]	0	256	2	8	RMSE	0.600 00
文献[16]	20	20	2	8	RMSE	0.100 00
文献[17]	20	100	2	5	RMSE	1.090 00
文献[18]	10	50	2	8	MAE\RMSE	0.090 00
文献[19]	10	100	1	10	AE\MSE	0.347 00
文献[23]	15	1 024	1	6	RMSE	0.800 00
文献[24]	-10	256	3	8	RMSE	0.200 00
文献[26]	0	—	32	128	MSE\BER	0.007 50
文献[27]	10	400	2	10	RMSE	0.200 00
文献[28]	5	—	2	4	MAE\ACC	0.600 0
文献[29]	-10	500	2	16	RMSE	0.700 00
文献[30]	0	256	1	6	MAE	0.987 60
文献[31]	-10	1 000	2	16	RMSE	0.500 00
文献[32]	20	—	4	10	RMSE	0.020 00
文献[33]	20	100	2	5	RMSE	1.200 00
文献[34]	10	400	1	10	MSE	0.200 00




图 9 评价标准占比

$$M_{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$
$$M_{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \tag{2}$$
$$R_{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

式中: n 为样本的个数; y_i 为真实值; \hat{y}_i 为预测值。MAE 计算的是误差绝对值的均值,这种方法不易受到误差相互抵消的影响,因而能够更准确地揭示预

测误差的实际水平,而 MSE 则是误差平方的平均,对异常值较为敏感,有助于揭示预测误差的分布特征。至于 RMSE,是 MSE 的平方根,主要用来衡量观测值与真实值之间的偏离程度。

5.2 影响 DOA 估计因素

波达方向估计的结果与入射信号源和应用环境有关^[35]。表 4~表 6 列出了文献中影响 DOA 估计的各种因素,包括信噪比、快照数量、训练批次大小,以下是对每个因素如何影响 DOA 估计的分析。

5.2.1 信噪比(SNR)对 DOA 估计的影响

SNR 直接影响超分辨 DOA 估计算法的性能。如表 4 所示,文献[7]中 SNR 从 0 dB 增加到20 dB,其 NMSE 约从 0 降低到-15。文献[32]中 SNR 从-20 dB增加到 20 dB,其 RMSE 约从 0.1 降低到 0.02。在文献[33]中,SNR 从 10 dB 增加到 20 dB,其 RMSE 约从 0.45 降至 0.29。而在文献[34]中,SNR 从-20 dB 增加到 20 dB 时,MSE 约从 0.25 降至 0.1。

表 4 不同信噪比下每种方法的估计性能

文献	信噪比/dB	NMSE
文献[7]	0	0
	10	-11
	20	-15
文献[32]	-20	0.10
	0	0.04
	20	0.02
文献[33]	10	0.45
	15	0.30
	20	0.29
文献[34]	-20	0.25
	0	0.20
	20	0.10

由表 4 中 SNR 与 RMSE 的关系可以看出,随着信号 SNR 的减小,算法的 DOA 估计性能也随之降低。因此,提高算法在低 SNR 条件下的 DOA 估计性能是高分辨率 DOA 估计算法的首要任务,这也是大多数论文讨论的重点内容。

5.2.2 快拍数对 DOA 估计的影响

快拍数的定义不同,在时域,定义为采样点的个数。在频域,定义为离散傅里叶变换的时间子段的个数。如表 5 所示,当 SNR=10 dB,文献[14]中,将

快照数量从 50 增加到 350,则 RMSE 从 0.56 降低到 0.28。文献[18]中,将快照数量从 0 增加到 100,则 MSE 从 7 降低到 0.1。文献[24]中,将快照数量从 0 增加到 500,则 RMSE 从 0.19 降低到 0.01。在 SNR=-20 dB,如果文献[29]中的快照数量从 100 增加到 10 000,则 RMSE 从 4 下降到 0.55。

表 5 不同快拍数下每种方法的估计性能

文献	快拍数	RMSE
文献[14]	50	0.560
	200	0.310
	350	0.280
文献[18]	0	7.000
	50	0.090
	100	0.100
文献[24]	0	0.190
	100	0.025
	500	0.010
文献[29]	100	4.000
	1 000	0.600
	10 000	0.550

由表 5 快照数量与评价标准之间的关系表明,随着快照数量的增加,大多数 DOA 估计方法的性能有所提高,且当快照数增加到一定程度时,估计性能不会有太大的变化。

5.2.3 训练批次大小对 DOA 估计的影响

仿真训练过程中,训练数据的批次大小也会影响 DOA 估计。批次大小是指在深度学习中,每次训练网络时输入数据的大小。表 6 给出了训练批次大小与评估标准之间的关系。文献[16]中,当隐藏层的数量为3层,且当 SNR=0 dB,批次大小从640

表 6 不同训练批次大小下每种方法的估计性能

文献	批次大小	RMSE
文献[16]	10	0.270 0
	640	0.250 0
	50 120	0.230 0
文献[19]	800	0.091 0
	2 000	-0.027 0
	50 000	0.107 0
文献[26]	10	0.006 0
	50	0.007 5
	100	0.080 0

增加到 5 120 则 RMSE 从 0.25 降低到 0.23。文献 [19] 选择测试集数据, 当 SNR = 0 dB, 批次大小从 800 增加到 5 000 则 AE 从 0.091 增加到 0.107。在 SNR = 0 dB 时, 如果文献 [26] 中的批次大小从 10 增加到 100 则 MSE 从 0.006 增加到 0.008。

由表 6 可知, 一般情况下, 设置较小的批大小可以进一步约束 MSE。同时, 我们可以发现在批量较大的情况下, DOA 估计性能趋于稳定。

6 结 语

深度学习技术由于其强大的学习能力, 可以当作一个黑匣子使用以减少计算量, 已经被应用于很多领域。本文对利用深度学习技术进行 DOA 估计的主要论文进行了系统性综述, 分析了在 DOA 估计中引入深度学习技术、各种深度学习模型的原因以及影响基于深度学习进行 DOA 估计方法的因素。

与传统算法相比, 基于深度学习的 DOA 估计算法的估计性能和泛化能力更胜一筹, 但在高噪声或强混响条件下性能仍有提升空间。基于大规模 MIMO 系统的 DOA 估计值得研究人员深入研究。因为不管是民用通信还是军队的电子频谱对抗, 分析的数据都是成指数级增长, 所以结合大规模 MIMO 系统以及深度学习的特点, 或许会有一些新的发现。

参考文献:

- [1] 闫锋刚, 沈毅, 刘帅, 等. 高效超分辨率波达方向估计算法综述 [J]. 系统工程与电子技术, 2015, 37(7): 1465-1475.
- [2] WANG N Y, AGATHOKLIS P, ANTONIOU A. A new DOA estimation technique based on subarray beamforming [J]. IEEE Transactions on Signal Processing, 2006, 54(9): 3279-3290.
- [3] 贺顺, 杨志伟, 张娟, 等. 自适应加权修正的强弱信号 Capon 谱估计方法 [J]. 系统工程与电子技术, 2013, 35(5): 905-908.
- [4] VALLET P, MESTRE X, LOUBATON P. Performance analysis of an improved MUSIC DoA estimator [J]. IEEE Transactions on Signal Processing, 2015, 63(23): 6407-6422.
- [5] ESPRIT: Estimation Of Signal Parameters Via Rotational Invariance Techniques-All Databases [EB/OL]. [2024-03-15].
- [6] REN J, YU L, LYU C, et al. Dynamical sparse signal recovery with fixed-time convergence [J]. Signal Process-ing, 2019, 162: 65-74.
- [7] 朱晗归, 冯存前, 冯可为, 等. 一种深度学习稀疏单快拍 DOA 估计方法 [J]. 信号处理, 2022, 38(10): 2114-2123.
- [8] 张骄, 王敏. 基于正交匹配追踪算法的虚拟内插空间平滑 DOA 估计 [J]. 测试技术学报, 2022, 36(5): 369-375.
- [9] 王秀红, 毛兴鹏, 张乃通. 基于降维稀疏重构的相干信源二维 DOA 估计方法 [J]. 系统工程与电子技术, 2016, 38(8): 1709-1715.
- [10] 邓伟鑫, 高晖, 唐勐, 等. 基于深度学习的室内目标波达方向估计 [J]. 无线电通信技术, 2024, 50(1): 152-161.
- [11] 余佳润, 王亚峰. 一种低信噪比下基于深度学习的 DOA 估计方法 [J]. 北京邮电大学学报, 2022, 45(6): 115-121.
- [12] 张永皓, 苏雪嫣, 胡蝶. 一种基于深度学习的环形阵列混合波束成型大规模 MIMO 系统 DOA 估计算法 [J]. 微型电脑应用, 2020, 36(11): 1-4.
- [13] CHEN M, GONG Y, MAO X. Deep neural network for estimation of direction of arrival with antenna array [J]. IEEE Access, 2020, 8: 140688-140698.
- [14] 葛晓凯, 胡显智, 戴旭初. 利用深度学习方法的相干源 DOA 估计 [J]. 信号处理, 2019, 35(8): 1376-1384.
- [15] WU L, LIU Z M, HUANG Z T. Deep Convolution Network for Direction of Arrival Estimation With Sparse Prior [J]. IEEE Signal Processing Letters, 2019, 26(11): 1688-1692.
- [16] XU S, BRIGHENTE A, CHEN B, et al. Deep Neural Networks for Direction of Arrival Estimation of Multiple Targets With Sparse Prior for Line-of-Sight Scenarios [J]. IEEE Transactions on Vehicular Technology, 2023, 72(4): 4683-4696.
- [17] KASE Y, NISHIMURA T, OHGANE T, et al. Accuracy Improvement in DOA estimation with deep Learning [J]. IEICE Transactions on Communications, 2022, E105/B(3): 588-599.
- [18] YANG Y, ZHANG M, PENG S, et al. Direction-of-Arrival estimation for a random sparse linear array based on a Graph Neural Network [J]. Sensors, 2023, 24(1): 91.
- [19] 韩莉. 阵列模型误差下基于机器学习的波达方向估计方法研究 [D]. 成都: 电子科技大学, 2022.
- [20] MCCULLOCH W, PITTS W. A logical calculus of the ideas immanent in nervous activity [J]. Bulletin of Mathematical Biology, 1990, 52(1-2): 99-115.
- [21] 刘曙光, 郑崇勋, 刘明远. 前馈神经网络中的反向传

- 播算法及其改进: 进展与展望[J]. 计算机科学, 1996 (1): 76-79.
- [22] GE S, LI K, RUM S N B M. Deep learning approach in DOA estimation: A systematic literature review [J]. Mobile Information Systems, 2021, 2021: 1-14.
- [23] 赵伟豪, 张君毅, 李淳. 基于深度学习的智能化高精度测向方法[J]. 计算机测量与控制, 2023, 31(1): 15-21.
- [24] 郭书涵, 胡国平, 赵方正, 等. 基于深度卷积神经网络的 DOA 估计[J]. 空军工程大学学报, 2023, 24(4): 62-68.
- [25] 田佳佳. 基于机器学习的阵列信号波达方向估计方法研究[D]. 南京: 南京信息工程大学, 2022.
- [26] HUANG H, YANG J, HUANG H, et al. Deep learning for super-resolution channel estimation and DOA estimation based massive MIMO system[J]. IEEE Transactions on Vehicular Technology, 2018, 67(9): 8549-8560.
- [27] LIU Z M, ZHANG C, YU P S. Direction-of-arrival estimation based on deep neural networks with robustness to array imperfections [J]. IEEE Transactions on Antennas and Propagation, 2018, 66(12): 7315-7327.
- [28] CHAKRABARTY S, HABETS E A P. Multi-speaker DOA estimation using deep convolutional networks trained with noise signals[J]. IEEE Journal of Selected Topics in Signal Processing, 2019, 13(1): 8-21.
- [29] PAPAGEORGIOU G, SELLATHURAI M, ELDAR Y. Deep networks for direction-of-arrival estimation in low SNR [J]. IEEE Transactions on Signal Processing, 2021, 69: 3714-3729.
- [30] 吴世龙, 唐希雯, 郑晨, 等. 阵列误差下基于稀疏表示与深度学习的 DOA 估计方法[C]//第十一届中国指挥控制大会论文集. 北京: 中国指挥与控制学会, 2023: 8.
- [31] QIN Y. Deep networks for direction of arrival estimation with sparse prior in low SNR [J]. IEEE Access, 2023, 11: 44637-44648.
- [32] 周巍, 张骄. 基于深度学习的相干循环平稳信号波达方向估计[J]. 山西大学学报(自然科学版), 2024, 47(5): 1028-1035.
- [33] KASE Y, NISHIMURA T, OHGANE T, et al. Performance analysis of DOA estimation of two targets using deep learning [C]//2019 22nd International Symposium on Wireless Personal Multimedia Communications (WPMC). Lisbon: IEEE Press, 2019: 1-6.
- [34] CHEN M, MAO X, WANG X. Performance analysis of deep neural networks for direction of arrival estimation of multiple sources [J]. IET Signal Processing, 2023, 17(3): e12178.
- [35] 俞帆, 陈格格, 沈明威. 基于双通道复数卷积神经网络的 DOA 估计算法[J]. 现代雷达, 2022, 44(12): 81-86.

作者简介

刘其有(2000—) 硕士研究生, 主要研究方向为智能超表面应用;

何 瑞(1998—) 硕士研究生, 主要研究方向为智能超表面应用;

施 伟(1977—) 博士, 副研究员, 主要研究方向为天线技术、阵列信号处理。